

Oppimistehtävä 1


Tekijä: Niko Heikkilä

Valitsin käsiteltäväksi datasetiksi netistä löytyvän Bostonin talojen hinnat csv tiedostossa. ([lähde](#)) Käyttötarkoituksena olisi analysoida dataa ja tehdä havaintoja esimerkiksi talojen arvojen eroista erilaisilla asuinalueilla.

- Datan tarkoitukset:
 - CRIM: Per capita rikollisuusaste kaupungissa
- ZN: Tämä ominaisuus kuvastaa asuintonttien osuutta, jotka on kaavoitettu yli 25 000 neliöjalan kokoisille alueille. Se ilmaisee määrän maata kussakin kaupungissa, joka on varattu suurille asuintonteille.
- INDUS: INDUS edustaa ei-vähittäiskaupan liiketoiminta-alueiden osuutta kaupungissa. Se kuvaa maan määrää, joka on omistettu ei-vähittäiskaupan liiketoiminnalle, kuten valmistukselle tai teollisille toimille, kussakin kaupungissa.
- CHAS: CHAS on dummy-muuttuja, joka kuvastaa, rajoittaako kaupunki Charles-joen. Se saa arvon 1, jos kaupunki rajoittuu jokeen, ja 0 muuten.
- NOX: NOX edustaa typpioksidien pitoisuutta (ilman saastumista) osina kymmenestä miljoonasta. Se mittaa ilman saastumisen tasoa kussakin kaupungissa.
- RM: RM tarkoittaa keskimääräistä huoneiden määrää asuntoa kohti. Se ilmaisee keskimääräisen huoneiden määrän taloissa tai asunnoissa kussakin kaupungissa.
- AGE: AGE edustaa omistusasuntojen osuutta, jotka on rakennettu ennen vuotta 1940. Se ilmaisee asuinrakennusten iän kussakin kaupungissa, korkeammat arvot osoittavat suuremman osuuden vanhoista kodeista.
- DIS: DIS tarkoittaa painotettuja etäisyyksiä viiteen Bostonin työkeskukseen. Se kuvaa keskimääräistä etäisyyttä kustakin kaupungista viiteen suureen työkeskukseen Bostonissa, pienemmät arvot osoittavat lähempää sijaintia.
- RAD: RAD on indeksi pääsystä säteittäisille moottoriteille. Se mittaa kunkin kaupungin pääsyä säteittäisille moottoriteille, korkeammat arvot osoittavat parempaa pääsyä.
- TAX: TAX edustaa kiinteistöveroprosenttia täydestä arvosta 10 000 dollaria kohti. Se ilmaisee kiinteistöveroprosentin kunkin kaupungin osalta, korkeammat arvot osoittavat korkeampia verokantoja.
- PTRATIO: PTRATIO edustaa oppilas-opettaja -suhdetta kaupungin kouluissa. Se kuvastaa keskimääräistä oppilaiden määrää opettajaa kohti kaupungin julkisissa kouluissa.
- B: Bk on osuus mustista väestöstä kaupungissa.
- LSTAT: Prosenttiosuus väestön alempiarvoisista kaupungeissa.


- MEDV: MEDV edustaa omistusasuntojen keskiarvoista arvoa 1000 dollareissa. Se ilmaisee omistusasuntojen keskihintaa kussakin kaupungissa, mikä on yleisesti käytetty mittari asuntomarkkinoiden arvosta.

Korrelaatio lämpökartta (MEDV):



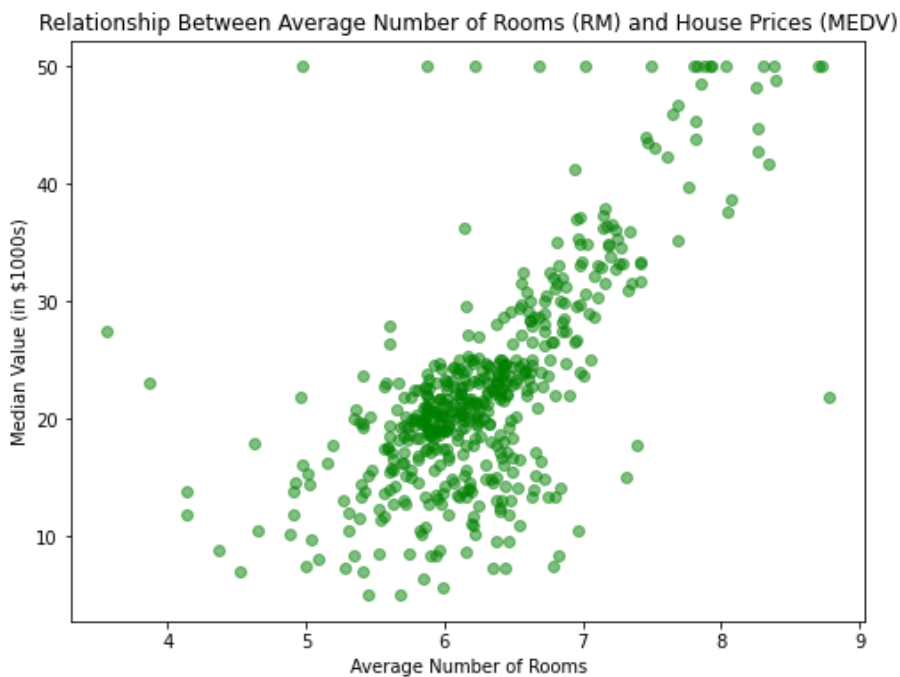
Tämä lämpökartta näyttää kaikkien kolumnien korrelaation (MEDV) kanssa, joka voi osoittaa tärkeitä negatiivisia tai positiivisia korrelaatioita MEDV suhteen, joka taas voi osoittaa tärkeitä ennusteita talojen hintoihin.

Histogrammi talojen hinnoista (MEDV):




Tämä histogrammi näyttää meille datasetin talojen mediaani hinnat.

Suhde huoneiden määrällä ja talon hinnalla:



Tällä scatter plotilla analysoidaan mediaani talon arvon ja talon huoneiden määrän suhdetta.

Oppilas-opettaja -suhdeluvun (PTRATIO) vaikutus talojen hintoihin (MEDV):



Tämä pylväsdiagrammi näyttää, miten oppilas-opettaja -suhdeluku koulussa kaupungeissa liittyy talojen mediaani hintaan kyseisissä kaupungeissa.

Oma arviointi:

Onnistuin mielestäni hyvin datasetin löytämisessä, se oli helpoin asia minulle. Ainoa kokemukseni pythonista ollen vain tämä kurssi tähän asti tarvitsen kyllä vielä paljon harjoitusta datan analysoinnista, tämän takia analyysini ja visualisoinnit jäivät simppeliksi.

Tähtään 1 arvosanaan.

Ensimmäiset 50 otosta datasta:

	CRIM	ZN	INDUS	CHAS	NOX	RM	AGE
	DIS	RAD	TAX	PTRATIO	B	LSTAT	MEDV
0	0.00632	18.0	2.31	0	0.538	6.575	65.2
	4.09	1	296.0	15.3	396.9	4.98	24.0

1	0.02731	0.0	7.07	0	0.469	6.421	78.9
	4.9671	2	242.0	17.8	396.9	9.14	21.6
2	0.02729	0.0	7.07	0	0.469	7.185	61.1
	4.9671	2	242.0	17.8	392.83	4.03	34.7
3	0.03237	0.0	2.18	0	0.458	6.998	45.8
	6.0622	3	222.0	18.7	394.63	2.94	33.4
4	0.06905	0.0	2.18	0	0.458	7.147	54.2
	6.0622	3	222.0	18.7	396.9	5.33	36.2
5	0.02985	0.0	2.18	0	0.458	6.43	58.7
	6.0622	3	222.0	18.7	394.12	5.21	28.7
6	0.08829	12.5	7.87	0	0.524	6.012	66.6
	5.5605	5	311.0	15.2	395.6	12.43	22.9
7	0.14455	12.5	7.87	0	0.524	6.172	96.1
	5.9505	5	311.0	15.2	396.9	19.15	27.1
8	0.21124	12.5	7.87	0	0.524	5.631	100.0
	6.0821	5	311.0	15.2	386.63	29.93	16.5
9	0.17004	12.5	7.87	0	0.524	6.004	85.9
	6.5921	5	311.0	15.2	386.71	17.1	18.9
10	0.22489	12.5	7.87	0	0.524	6.377	94.3
	6.3467	5	311.0	15.2	392.52	20.45	15.0
11	0.11747	12.5	7.87	0	0.524	6.009	82.9
	6.2267	5	311.0	15.2	396.9	13.27	18.9
12	0.09378	12.5	7.87	0	0.524	5.889	39.0
	5.4509	5	311.0	15.2	390.5	15.71	21.7
13	0.62976	0.0	8.14	0	0.538	5.949	61.8
	4.7075	4	307.0	21.0	396.9	8.26	20.4
14	0.63796	0.0	8.14	0	0.538	6.096	84.5
	4.4619	4	307.0	21.0	380.02	10.26	18.2
15	0.62739	0.0	8.14	0	0.538	5.834	56.5
	4.4986	4	307.0	21.0	395.62	8.47	19.9
16	1.05393	0.0	8.14	0	0.538	5.935	29.3
	4.4986	4	307.0	21.0	386.85	6.58	23.1
17	0.7842	0.0	8.14	0	0.538	5.99	81.7
	4.2579	4	307.0	21.0	386.75	14.67	17.5
18	0.80271	0.0	8.14	0	0.538	5.456	36.6
	3.7965	4	307.0	21.0	288.99	11.69	20.2
19	0.7258	0.0	8.14	0	0.538	5.727	69.5
	3.7965	4	307.0	21.0	390.95	11.28	18.2
20	1.25179	0.0	8.14	0	0.538	5.57	98.1
	3.7979	4	307.0	21.0	376.57	21.02	13.6

21	0.85204	0.0	8.14	0	0.538	5.965	89.2
	4.0123	4	307.0	21.0	392.53	13.83	19.6
22	1.23247	0.0	8.14	0	0.538	6.142	91.7
	3.9769	4	307.0	21.0	396.9	18.72	15.2
23	0.98843	0.0	8.14	0	0.538	5.813	100.0
	4.0952	4	307.0	21.0	394.54	19.88	14.5
24	0.75026	0.0	8.14	0	0.538	5.924	94.1
	4.3996	4	307.0	21.0	394.33	16.3	15.6
25	0.84054	0.0	8.14	0	0.538	5.599	85.7
	4.4546	4	307.0	21.0	303.42	16.51	13.9
26	0.67191	0.0	8.14	0	0.538	5.813	90.3
	4.682	4	307.0	21.0	376.88	14.81	16.6
27	0.95577	0.0	8.14	0	0.538	6.047	88.8
	4.4534	4	307.0	21.0	306.38	17.28	14.8
28	0.77299	0.0	8.14	0	0.538	6.495	94.4
	4.4547	4	307.0	21.0	387.94	12.8	18.4
29	1.00245	0.0	8.14	0	0.538	6.674	87.3
	4.239	4	307.0	21.0	380.23	11.98	21.0
30	1.13081	0.0	8.14	0	0.538	5.713	94.1
	4.233	4	307.0	21.0	360.17	22.6	12.7
31	1.35472	0.0	8.14	0	0.538	6.072	100.0
	4.175	4	307.0	21.0	376.73	13.04	14.5
32	1.38799	0.0	8.14	0	0.538	5.95	82.0
	3.99	4	307.0	21.0	232.6	27.71	13.2
33	1.15172	0.0	8.14	0	0.538	5.701	95.0
	3.7872	4	307.0	21.0	358.77	18.35	13.1
34	1.61282	0.0	8.14	0	0.538	6.096	96.9
	3.7598	4	307.0	21.0	248.31	20.34	13.5
35	0.06417	0.0	5.96	0	0.499	5.933	68.2
	3.3603	5	279.0	19.2	396.9	9.68	18.9
36	0.09744	0.0	5.96	0	0.499	5.841	61.4
	3.3779	5	279.0	19.2	377.56	11.41	20.0
37	0.08014	0.0	5.96	0	0.499	5.85	41.5
	3.9342	5	279.0	19.2	396.9	8.77	21.0
38	0.17505	0.0	5.96	0	0.499	5.966	30.2
	3.8473	5	279.0	19.2	393.43	10.13	24.7
39	0.02763	75.0	2.95	0	0.428	6.595	21.8
	5.4011	3	252.0	18.3	395.63	4.32	30.8
40	0.03359	75.0	2.95	0	0.428	7.024	15.8
	5.4011	3	252.0	18.3	395.62	1.98	34.9

41	0.12744	0.0	6.91	0	0.448	6.77	2.9
	5.7209	3	233.0	17.9	385.41	4.84	26.6
42	0.1415	0.0	6.91	0	0.448	6.169	6.6
	5.7209	3	233.0	17.9	383.37	5.81	25.3
43	0.15936	0.0	6.91	0	0.448	6.211	6.5
	5.7209	3	233.0	17.9	394.46	7.44	24.7
44	0.12269	0.0	6.91	0	0.448	6.069	40.0
	5.7209	3	233.0	17.9	389.39	9.55	21.2
45	0.17142	0.0	6.91	0	0.448	5.682	33.8
	5.1004	3	233.0	17.9	396.9	10.21	19.3
46	0.18836	0.0	6.91	0	0.448	5.786	33.3
	5.1004	3	233.0	17.9	396.9	14.15	20.0
47	0.22927	0.0	6.91	0	0.448	6.03	85.5
	5.6894	3	233.0	17.9	392.74	18.8	16.6
48	0.25387	0.0	6.91	0	0.448	5.399	95.3
	5.87	3	233.0	17.9	396.9	30.81	14.4
49	0.21977	0.0	6.91	0	0.448	5.602	62.0
	6.0877	3	233.0	17.9	396.9	16.2	19.4
50	0.08873	21.0	5.64	0	0.439	5.963	45.7
	6.8147	4	243.0	16.8	395.56	13.45	19.7

Koodi:

```
import pandas as pd
```

```
import matplotlib.pyplot as plt
```

```
import seaborn as sns
```

```
#Naming Columns
```

```
column_names=['CRIM', 'ZN', 'INDUS', 'CHAS', 'NOX', 'RM', 'AGE', 'DIS', 'RAD', 'TAX', 'PTRATIO', 'B', 'LSTAT', 'MEDV']
```

```
data= pd.read_csv('housing.csv',header=None, delimiter=r'\s+', names=column_names)
```

```
# Compute the correlation matrix
```

```
correlation_matrix = data.corr()
```

```
# Create a heatmap
```

```
plt.figure(figsize=(12, 8))
```

```
sns.heatmap(correlation_matrix, annot=True, cmap="coolwarm")
```

```
plt.title("Correlation Heatmap")
```

```
plt.show()
```

```
# Histogram of housing prices (MEDV)
```

```
plt.figure(figsize=(8, 6))
```

```
sns.histplot(data['MEDV'], kde=True, bins=30, color='blue')
```

```
plt.title("Distribution of House Prices (MEDV)")
```

```
plt.xlabel("Median Value (in $1000s)")
```

```
plt.ylabel("Frequency")
```

```
plt.show()
```

```
# Relationship between rooms (RM) and house prices (MEDV)
```

```
plt.figure(figsize=(8, 6))
```

```
plt.scatter(data['RM'], data['MEDV'], alpha=0.5, color='green')
```

```
plt.title("Relationship Between Average Number of Rooms (RM) and House Prices (MEDV)")
```

```
plt.xlabel("Average Number of Rooms")
```

```
plt.ylabel("Median Value (in $1000s)")
```

```
plt.show()
```

```
# Impact of pupil-teacher ratio (PTRATIO) on house prices (MEDV)
```

```
# Group data by PTRATIO and calculate the median MEDV for each group
```

```
ptratio_median = data.groupby('PTRATIO')['MEDV'].median().reset_index()
```

```
# Create a bar plot
```

```
plt.figure(figsize=(12, 6))
```

```
sns.barplot(x='PTRATIO', y='MEDV', data=ptratio_median, palette="viridis")
```

```
plt.title("Impact of Pupil-Teacher Ratio (PTRATIO) on House Prices (MEDV)")
```

```
plt.xlabel("Pupil-Teacher Ratio")
```

```
plt.ylabel("Median Value (in $1000s)")
```

```
plt.xticks(rotation=90)
```

```
plt.show()
```